眼动实验数据复算与研究复盘报告

基于历史课程实验的任务恢复 数据复核与结果重述

作者 四件 实验所属报告年份 2025 复算与成文日期 2026年10月17日

研究概述

本报告重新整理课程实验保留的眼动工程与导出文件，恢复任务、目标区域和逐人跨场景关系，并复核历史报告中的部分结论。共识别16个图像场景、13个被试标识，形成208条被试与场景汇总。实验覆盖目标查找、信息流浏览、会员区域查找及购买或教程入口查找，不应统一概括为单一的会员复杂度实验。

复算确认四个会员场景来自同一组13人的重复测量。对目标区域注视时长、注视条目数和时长占比进行被试内探索比较后，三项检验经Holm校正均未达到0.05。现有数据不足以支持某种会员界面复杂度导致更好体验的结论，也不能据此证明四种界面效果相同。

历史报告的部分均值尚不能按现存导出口径复现；主观侵入感评分的来源也未恢复。这些问题应保留为待核对事项，不能直接推断原始实验虚假，也不能用推测补齐评分。

工作归属与时间边界

2025年的实验由团队共同开展，我参与实验测试，并负责部分测试材料的撰写。根据本人回忆，该部分可能属于靠后的环节，具体场景尚不能可靠对应。我基于团队共享的初始资料独立完成个人报告及其中的数据分析，并使用AI辅助分析和表达。现有材料不足以把全部实验设计、设备操作或数据采集归为个人独立完成。

2026年的工作为历史资料整理与复算：恢复16场景任务目录，校验目标区域，修正重复测量的分析口径，生成匿名汇总，并重新讨论证据限制。该工作不追溯为2025年已经完成的研究步骤。适老化游戏问卷与设计方案属于另一部分，本报告不重新计算其结果。

一 实验任务恢复

以工程中的指导语和场景内部名称恢复任务。代码仅用于本报告阅读，不改变原工程场景名。手动场景以按空格结束；自动浏览场景设定约10秒。

代码	工程场景	任务及结束方式
P1	位置	查找帖子点赞数量 按空格
P2	位置2	查找会员中心 按空格
P3	位置3	查找缴付账单 按空格
P4	位置4	查找热点 按空格
F1	信息流	浏览10秒 随后回答广告数量
F2	信息流1	浏览10秒 随后回答广告数量
F3	信息流2	浏览10秒 随后回答广告数量
M1	会员1	查找会员区域 按空格
M2	会员2	查找会员区域 按空格
M3	会员3	查找会员区域 按空格
M4	会员4	查找会员区域 按空格
T1	任务类型	查找双十一入口 按空格
T2	任务类型-Copy	自由浏览10秒 随后判断应用类型
E1	1 (2)	查找洗浴用品购买入口 按空格
E2	2 (2)	查找新手教程 按空格
E3	3 (2)	查找面膜购买入口 按空格

这些任务能够观察什么

目标查找任务主要记录指定目标的视觉搜索与注意分配；信息流浏览后的问答记录广告数量判断；应用类型问答记录对界面类别的判断。它们并未直接测量完整操作流程、购买转化或长期使用体验。

“找到后按空格”是参与者自行报告找到目标。注视进入目标区域、按下空格与正确识别目标，三者不能互相替代。现存记录缺少目标点击与正确性核验，因此不计算任务成功率，也不把场景时长直接命名为正确完成时间。

二 数据处理与指标定义

输入与样本结构

分析读取保留工程中的场景、指导语、兴趣区多边形、场景开始结束时间和Subjects的info问答字段，并对应GazeTrack与GazeAOI导出。使用广告3工程；广告1工程不重复计入，汽车外形工程不纳入。本次使用软件已经生成的注视条目，未重新解析二进制眼动信号，也未重新运行注视检测。

16个场景各有13个相同的被试标识。统计单位为被试，不把注视条目数当作样本量，也不把四个会员场景中的13人累计为52名独立参与者。年龄、视力、校准质量等背景不能由当前汇总推断，因此不能将该样本称为老年用户样本。

筛选与区域校验

主分析保留持续时间不小于0.05秒的注视条目，与历史报告描述的阈值对齐；这只是处理选择，不是普适有效性标准。另保留0秒与0.10秒阈值的描述性敏感性汇总，不通过调整阈值挑选显著结果。主阈值下有14条过短记录被排除。

从工程恢复AOI多边形，以注视点是否位于区域内匹配，边界计入区域；场景的多个目标区域取并集。重新计算的各命名AOI被注视人数比例均与可对应的软件导出一致。这支持本次区域恢复和坐标处理的一致性，但不等于所有软件统计均已复现。

指标	定义与解释
全场景注视时长	保留条目时长之和 不等于目标查找时间
目标AOI时长与条目数	落入目标区域的时长及条目数 无命中者计0
目标时长占比	先计算每人的目标时长除以全场景时长 再汇总
首次目标注视时间	仅对检测到目标注视者统计 无命中者保留缺失
场景展示时长	工程结束时间减开始时间 含反应与切换开销

时间与缺失处理

工程时间按每秒一千万时间单位换算。52条配置为10秒的自动展示记录换算为约10.02至10.11秒，与设置相符。未配置AOI的自由浏览场景不填区域指标；未命中目标者的首次注视时间不能填0，否则会错误表示目标被立即发现。

三 会员区域查找的复算结果

四个会员场景均有13人的完整配对。下表区分全场景注视和目标区域注视；均值不是逐条注视事件的平均。

场景	全场景时长 秒	目标时长 秒	目标时长占比	目标命中人数
会员1	5.575	3.115	61.1%	13/13
会员2	3.450	1.685	61.7%	12/13
会员3	2.512	2.117	86.1%	13/13
会员4	2.908	1.775	65.0%	12/13

指标	Friedman Q	置换 p	Holm p	Kendall W
目标注视时长	7.9767	0.04356	0.08712	0.2045
目标注视条目数	6.0242	0.10854	0.10854	0.1545
目标时长占比	8.7600	0.02864	0.08592	0.2246

使用含并列秩修正的Friedman Q，以99,999次被试内标签置换估计p值；三个指标统一进行Holm校正。检验为未预注册的探索，且依赖被试内可交换等假设。场景顺序若固定，顺序与材料效应无法分离。Q值另与SciPy核对；未以四条件下的渐近卡方p值作为主要结果。

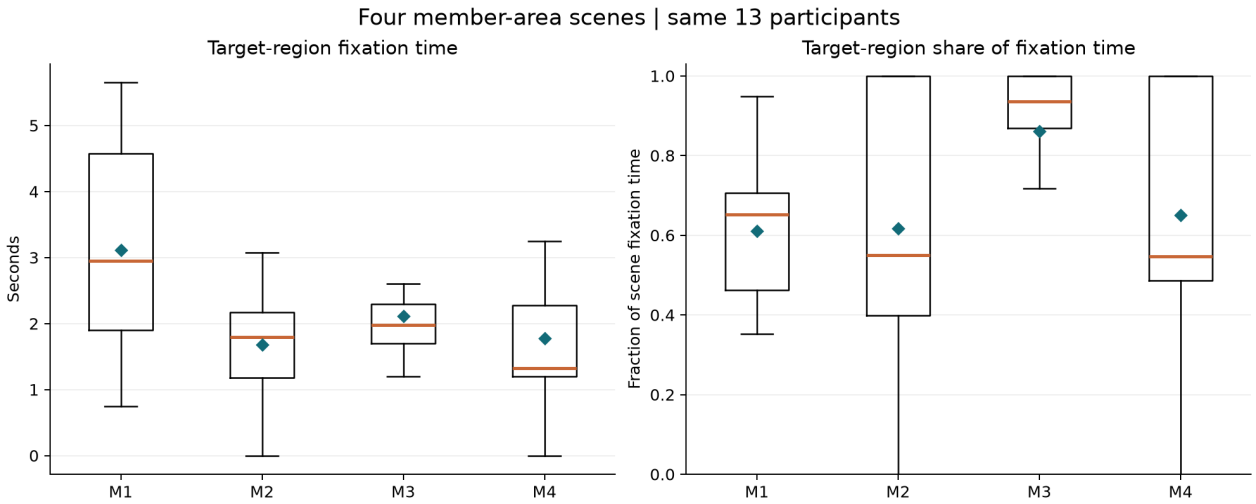


图1 会员场景的目标区域指标分布 每个场景13人

两个未校正p值低于0.05，但三项校正后均未达到阈值，因此不继续挑选两两显著比较。M3目标时长占比的均值较高，不能直接等同于更好理解或更好体验。四个AOI面积占画面约8.21%、6.50%、9.29%、7.53%，同时存在材料、内容、熟悉度和展示时长差异。

四 全部场景与附带问答

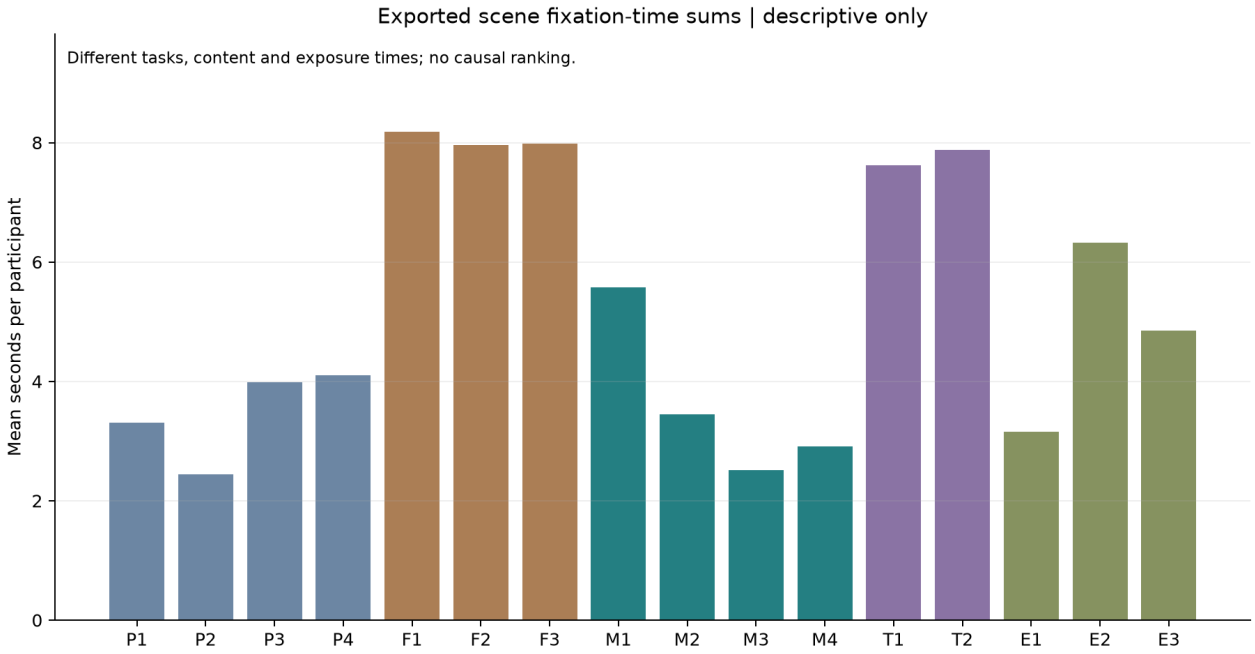


图2 全16场景的全场景注视时长均值 仅作描述

P为位置组，F为信息流组，M为会员组，T为任务类型组，E为其他入口组。自动浏览场景固定约10秒，手动查找场景由参与者按键结束，因此不能用柱高对应用效率或界面质量排序。全量均值、标准差、中位数与四分位数保存在配套汇总表。

工程中保留的问答分布

记录项	保存答案及人数
第一组广告数量	1个 10人 2个 1人 3个 2人
第二组广告数量	2个 1人 3个 2人 4个 10人
第三组广告数量	1个 13人
应用类型	购物 12人 餐饮 1人

上述频数来自Subjects的info字段。Recording字段含有不同的默认值，未将两者混用或重复计数。由于字段映射尚未通过原软件重新导出作最终确认，且正确答案未独立核对，结果仅作为保存答案的频数，不解释为广告识别正确率。

主观侵入感暂不重算

现存材料尚不能核实主观侵入感评分来源，因此未纳入本次复算。后续如恢复明确的评分题、逐份答卷及编码规则，可再核对其与历史表格的对应关系。

广告数量判断属于识别任务，主观侵入感属于体验评价，不能将前者替换为后者。本次不生成缺失评分，不重算原侵入感回归，也不把眼动记录真实作为主观评分来源可靠的证明。

五 历史结论的修正与研究限制

历史均值尚不能直接复现

场景	历史全场景均值 秒	本次全场景均值 秒	本次目标区域均值 秒
会员2	5.23	3.450	1.685
会员3	3.18	2.512	2.117
会员4	4.85	2.908	1.775

差异可能来自导出版本、筛选条件、区域定义或分析错误。原计算文件已经遗失，现阶段无法确认具体原因。保留历史报告并新增日期明确的复算版本，比直接覆盖原表更有利于追踪口径变化。

分析单位需要修正

历史报告将部分场景按组间比较描述；现存记录显示四个会员场景是同一13人的重复测量。本次据此改用被试内探索方法。重复测量方法能处理同一个人的关联，却不能消除跨产品材料、区域面积或任务顺序造成的混杂。

不能把注视越久解释为体验越好

较长注视可能来自注意吸引、阅读内容较多、搜索困难或停留时间较长；仅凭时长不能判断理解深度。同样，较短注视可能意味着迅速找到目标，也可能意味着没有注意到。解释应同时依赖正确性、任务完成、首次目标注视、主观反馈等证据，而当前记录只覆盖其中一部分。

任务与材料的控制不足

部分材料来自不同产品和页面，目标语义、视觉密度、面积与用户熟悉度可能同时变化。“位置”“会员”等工程名称不能自动视为受到控制的单一实验因素。当前材料适合作为课程探索和研究流程练习，不足以形成普遍的布局因果结论。

样本与记录的适用范围有限

样本仅13人，参与者背景与校准质量未在本次复算中重新核验，且没有独立的目标点击正确性。统计未达阈值不是界面等效的证明。报告不能推出老年群体的偏好，也不能据此验证适老化游戏玩法。缺失的原分析文件和主观量表限制了历史结论的可追溯性。

六 后续研究建议与资料管理

如果重新设计实验

先把问题限定到一个具体判断，例如“在内容和位置一致时，会员入口的显著性变化是否影响目标查找”。采用同一界面模板，仅改变目标因素；统一目标语义、内容量、区域面积及展示方式。若必须比较不同产品，应将其定义为产品案例比较，不将差异归因于某个单独因素。

为每个任务保存正确目标、点击位置或答案及完成状态，将正确率和正确完成时间与眼动指标配合使用。记录任务顺序并进行随机化或平衡，保存设备参数、校准与有效数据标准。先做小规模预试，再根据主要指标和预期精度确定样本方案；不直接把13人作为充分性依据。

如研究适老化，应明确招募对象并记录相关使用经验；将广告识别、任务查找和主观侵入感分开设计。主观评价保留题目、量尺、逐份答卷、编码规则和缺失处理，不事后根据眼动结果补造态度评分。

本次整理记录

环节	本次完成内容
资料定位	恢复16场景与指导语 识别重复导出及无关工程
数据核对	逐人对齐208条汇总 核对AOI命中比例和展示时间
复算与解释	统一筛选及指标定义 进行配对探索与多重校正
报告修订	分离历史与复算结论 标出无法复现及待核实部分
公开准备	仅保留汇总图表和方法 原始身份及逐人资料留在本地

隐私与可复核范围

公开材料使用作者名“四件”，不包含同学姓名、身份对照表、逐人轨迹、逐人问答或原始刺激截图。被试标识在本地去标识处理后用于配对；身份映射不另行保存。小样本汇总不等于形式化的不可重识别证明。原始输入不公开，读者可以审查代码与汇总，但无原始材料时不能独立复现全部计算。

结论

本次复算的主要成果是恢复实验结构、校正分析口径并明确解释边界。现有结果支持对目标查找和注意分配的有限描述，不支持以注视时长单独判定界面优劣。后续应优先补齐正确性、主观量表来源和实验控制，再开展面向具体设计问题的验证。

方法参考与配套资料

统计方法参考：SciPy friedmanchisquare、SciPy wilcoxon及statsmodels multipletests官方文档。具体地址与复算命令见配套METHODS.md。场景目录、汇总结果、检验结果与匿名规则分别见TASKS.md、data/scene_summary.csv、data/member_tests.csv和PRIVACY.md。

Friedman检验说明

配对秩检验说明

多重检验校正说明